某高端装备制造企业案例

行业大模型
训练与优化案例

从专业文档到可验证的能力提升

客户拥有大量专业手册、标准和历史资料。数据结构不统一，难以直接支撑行业模型训练与持续迭代。

客户挑战与项目目标

01 知识分散

手册、标准和历史资料分布在不同系统中，格式与质量差异明显。

02 标注投入高

专家时间有限，纯人工整理难以兼顾规模、速度和一致性。

03 回答缺乏依据

通用模型对行业术语理解不足，回答容易出现遗漏或无依据扩展。

04 效果难量化

缺少统一基准与对照评测，模型提升无法稳定复现和解释。

项目目标

知识可追溯、训练可复现、效果可衡量和团队可持续运营

量化成效

1,000条测试问答样本。基座与SFT回答随机映射。独立裁判模型在统一标准下评分。

平均提升

+16.0 分

基座模型 65.94

SFT模型 81.975

来源：项目测试报告。平均提升16.035分。

显著提升

88.2%

样本得分提高至少5分

项目环境下的一轮工程验证

约32h → 约3.5h

训练时长由约32小时降至约3.5小时，效率提升近9倍。

评测口径 所有结果来自统一推理参数下的对照评测。按5分阈值计算，Good Rate为88.2%。

方案总览

方案以数据质量和可验证改进为主线，将专业文档处理、知识组织、监督微调和对照评测串成一条可重复运行的工程链路。

01

数据工程自动化

对OCR文本执行清洗、质量准入和结构化处理，分离合格、拒绝与失败记录，支持批量运行和断点续跑。

文本准入与清洗

02

可审计知识资产

抽取专业术语、领域归属和有证据支持的关系，形成局部知识单元，并保留来源信息供抽检与追溯。

术语和关系抽取

03

模型训练与优化

将知识单元转换为对话训练样本，固化训练配置，并通过样本打包、参数基线和退化样本回流提升效率与稳定性。

训练样本生成

04

量化评测闭环

在统一推理条件下对基座模型和行业SFT模型进行匿名盲评，按领域分析提升、持平和退化样本。

退化治理

原文证据约束 | 每条知识单元关联来源文本。模型只能围绕命中证据生成术语、关系和解释。

可审计的数据资产 来源信息可按交付口径保留。

失败可恢复 支持断点续跑和问题样本复核，减少重复计算。

评测方法

固定随机种子构建1,000条可复现问答。推理阶段统一最大输出长度和关键解码参数。

1

统一基准

固定随机种子构建1,000条可复现问答。

2

推理阶段

推理阶段统一最大输出长度和关键解码参数。

3

匿名盲评

系统随机将基座与SFT回答映射为A或B。

4

退化治理

以5分差值划分提升、持平和退化。团队按领域聚合退化样本，再回溯训练数据、系统提示和答案长度。

独立裁判模型依据标准答案评估

- 准确性
- 完整性
- 术语规范
- 无依据扩展

跨领域一致性

六类知识域的SFT平均分均高于基座模型。

+16.1 分

按领域等权计算
宏平均提升约

每个分数都能回到具体问题、标准答案、模型回答和裁判理由，便于业务复核。

工程化交付

交付重点是可运行的方法体系，包括配置、质量门槛、复现步骤和评测脚本，降低后续维护与交接成本。

标准接口与批处理 A

通过兼容接口接入模型服务，统一运行参数、批量处理、失败重试和输出格式，便于集成现有数据与训练环境。

可审计的数据资产 B

每条通过准入的记录形成局部知识单元，并输出为SFT对话或Community数据。来源信息可按交付口径保留。

训练策略 C

统一系统提示与消息格式；固定随机种子和复现配置；保留来源与质量元数据。

评测结果可解释 D

每个分数都能回到具体问题、标准答案、模型回答和裁判理由，便于业务复核。

数据飞轮与训练飞轮 E

操作手册覆盖小样本试跑、正式生成、训练复现、结果评测和问题回流。团队可独立更新数据并完成下一轮迭代。

团队具备自主迭代能力 F

通过运行手册、配置基线和评测流程，客户团队可独立完成数据更新与模型复验。

经验与下一步

评测显示模型在所有知识域均有提升，但收益并不均衡。标准规范和仿真建模相关样本仍是下一轮优化重点。

业务与工程价值

01 训练数据可持续更新

新文档可沿同一质量流程进入知识抽取和训练数据生成，减少重复整理工作。

02 评测结果可解释

每个分数都能回到具体问题、标准答案、模型回答和裁判理由，便于业务复核。

03 薄弱领域可定位

分域结果显示不同知识域收益不均，为下一轮补数、清洗和复训提供明确优先级。

04 团队具备自主迭代能力

通过运行手册、配置基线和评测流程，客户团队可独立完成数据更新与模型复验。

下一步

以下为原材料中的下一步规划

优先治理薄弱领域

补充标准规范和仿真建模材料，复核退化样本中的术语歧义、答案长度和证据缺口。

扩展多模态输入

在文字流程稳定后，逐步引入表格、图纸和设备影像，并为每类输入建立独立质量门槛。

强化轻量化部署

结合量化、缓存和检索增强，评估私有环境中的响应时延、资源占用和答案一致性。

持续建设知识资产

建立版本、来源和质量记录，保持训练集、评测集与业务知识更新节奏一致。